

Kiến trúc hướng dịch vụ INT3505

Bài tập lớn số hai

Tìm hiểu về Message-oriented Middleware

Nguyễn Việt Minh Nghĩa
nvmnghia@gmail.com

11/04/2020

1 Giới thiệu

1.1 Tiền đề

Với sự phát triển của công nghiệp bán dẫn, máy tính ngày nay trở nên nhanh hơn, phổ biến hơn. Tuy nhiên, do hạn chế về vật lý, việc tăng tốc phần cứng của một hệ thống phần mềm không thể chỉ thực hiện được bằng cách làm ra một máy tính lớn hơn, mạnh hơn (scale up), mà còn phải bằng cách tăng số lượng các máy (scale out).

Cùng với sự phát triển của phần cứng, phần mềm cũng trở nên phức tạp hơn. Một hệ thống phần mềm ngày nay gồm nhiều hệ thống con có mức chuyên biệt hóa cao hoạt động độc lập, thay vì một khối phần mềm lớn (monolithic) như trước. Cho dù các thành phần của hệ thống này cùng chạy trên một máy, chúng cũng không thể đơn giản là dùng chung một khối bộ nhớ, do cơ chế bảo mật địa chỉ ảo của hệ điều hành.

Hai vấn đề này cùng dẫn đến nhu cầu kết nối các máy tính (hay cụ thể hơn, các tiến trình) với nhau, và trao đổi dữ liệu giữa chúng. Với sự phát triển của mạng máy tính tốc độ cao, các giải pháp kết nối máy tính bắt đầu có thể thực hiện được. Xét về mặt phần mềm, các cơ chế để giải quyết vấn đề này được gọi là giao tiếp liên tiến trình, thường gọi là IPC (viết tắt của inter-process communication).

1.2 Giao tiếp liên tiến trình - IPC

Có rất nhiều cơ chế để liên lạc giữa các tiến trình với nhau, nổi bật trong số đó có RPC - Remote Procedure Call. Hai trong những lý do cho sự phổ biến của RPC là nó có thể giúp cho các tiến trình ở các máy khác nhau giao tiếp được với nhau, đồng thời không phụ thuộc vào ngôn ngữ. Nhiều phương pháp cũ hơn như file, pipe, shared memory,... đều không thể thực hiện việc này [8]. Tuy nhiên, RPC và các biến thể của nó như ORB rất khó đáp ứng với các yêu

cầu mới về độ ổn định, khả năng hoạt động liên tục và hiệu năng, khiến nó dần trở nên lỗi thời.

Để giải quyết các hạn chế của RPC, có một cơ chế mới đang được sử dụng rất nhiều hiện nay là Message-oriented Middleware, viết tắt là MOM.

1.3 Message-oriented Middleware

MOM là một lớp trung gian giúp gửi và nhận dữ liệu *theo kiểu thông điệp* (message-passing) giữa hai tiến trình khác nhau. Các danh từ khác thường được coi là đồng nghĩa với MOM là hàng đợi thông điệp (message queue), hay trung gian chuyển thông điệp (message broker).

Thông thường, một hệ thống MOM có ba thành phần:

- Producer: Nguồn gửi thông điệp
- Broker: Trung gian trung chuyển thông điệp
- Consumer: Điểm nhận thông điệp

Ý tưởng trung tâm của MOM là giao tiếp bằng *thông điệp*. Thông tin được gửi ở dạng thông điệp, giống như tin nhắn hay gửi thư, thay thế cho việc producer phải chủ động liên lạc trực tiếp với consumer. Nói cách khác, producer được *giải phóng khỏi việc gửi thông tin*.

Hình 1 mô tả kiến trúc của một MOM đơn giản, với ba thành phần kể trên (mũi tên chỉ hướng đi của thông điệp):




Figure 1: Kiến trúc chung của MOM.

Bài này sẽ phân tích các đặc điểm và kiến trúc cơ bản của một hệ thống MOM, đồng thời giới thiệu về Apache Kafka, một trong các MOM được sử dụng nhiều nhất hiện nay.

2 Đặc điểm

Để tìm hiểu đặc điểm của MOM, ta có thể so sánh MOM với một cơ chế IPC khác có khả năng gần giống là RPC.

2.1 Tính bất đồng bộ - Asynchrony

Tính bất đồng bộ là đặc điểm quan trọng nhất của ý tưởng giao tiếp thông qua thông điệp [4]. Thuộc tính này nghĩa là producer chỉ cần "gửi" một thông điệp, thông điệp đó sẽ được broker đưa đến consumer phù hợp để xử lý. Để thấy rõ lợi ích của tính bất đồng bộ, ta có thể so sánh với RPC đồng bộ (có RPC bất đồng bộ, nhưng ta tạm thời bỏ qua).

Với RPC, khi client gọi một hàm của server, dữ liệu (ở dạng các tham số đầu vào) được marshall và gửi sang server. Sau khi server xử lý xong, dữ liệu (kết quả đầu ra) lại được gửi lại client. Trong suốt thời gian gửi-xử lý-nhận đó, client phải chờ (blocking), gây ra chậm trễ đáng kể và lãng phí thời gian. Nếu có vấn đề về mạng, hoặc một lý do nào khác không thể gửi/nhận dữ liệu, client phải gửi lại.

Với MOM, khi producer gọi muốn gửi dữ liệu sang consumer, producer chỉ cần giao dữ liệu cho broker, và broker sẽ tự gửi đến consumer. Ngay sau đó, producer có thể làm việc khác, không phí thời gian chờ kết quả. Nếu ngay lúc đó consumer không thể nhận được dữ liệu, broker sẽ chờ đến khi consumer có thể nhận được dữ liệu rồi gửi lại, đảm bảo gửi ít nhất một lần.

Cần chú ý rằng MOM không thể, và không được thiết kế để thay thế hoàn toàn RPC. Lý do chính nằm ở chi tiết producer không chờ lấy dữ liệu kết quả. MOM hoàn toàn không cung cấp một cơ chế riêng nào giúp consumer trả kết quả cho producer, trái ngược với tính liên lạc hai chiều của RPC. Nếu muốn lấy kết quả, hai bên producer và consumer đổi vai cho nhau, và cần một kết nối khác. Điều này khiến cho RPC vẫn có chỗ đứng riêng, đồng thời khiến cho việc thiết kế hệ thống dùng MOM khác biệt đáng kể với hệ thống dùng RPC. MOM chỉ phù hợp với hệ thống có dữ liệu không có sự phụ thuộc lẫn nhau [7].

2.2 Tách rời bên gửi - bên nhận - Decoupling

Một đặc điểm quan trọng khi tách việc "gửi" dữ liệu khỏi producer là việc gửi đi đâu hoàn toàn nằm trong tay broker. Động từ "gửi" được dùng theo nghĩa là một bên muốn bên kia biết được một thông tin nào đó. Để có thể gửi, bên gửi cần biết thông tin bên nhận. Tuy nhiên, với MOM, bên "gửi" - producer - có thể không cần biết thông tin của bên "nhận" - consumer. Producer không cần biết rằng consumer nào nhận, chứ chưa nói đến việc có bao nhiêu consumer nhận, hay đã nhận được thực sự chưa.

Nói đơn giản, với producer và người dùng, MOM là một dịch vụ gửi thông điệp theo kiểu bắn-và-quên. Hệ thống MOM do đó đạt được sự tách rời gửi-nhận.

Tiếp tục so sánh với RPC, bên gửi cần biết thông tin về bên nhận (ví dụ như địa chỉ IP, tên hàm,...). Nếu có nhiều bên nhận, bên gửi phải xử lý việc gửi cho mọi bên nhận, bao gồm những việc như chờ, gửi lại nếu bị lỗi,..., do đó tốn nhiều thời gian. Đặc biệt, với các hệ thống đám mây, nơi một máy chủ ảo bị xóa, tắt, hoặc tạo mới diễn ra thường xuyên thì mạng kết nối đầy đủ, chặt chẽ (fully connected network) mà RPC tạo ra sẽ rất phức tạp và khó bảo trì [5], giống như biếm họa trong hình 2.




Figure 2: Kiến trúc SpaghettiTM[9].

Với hai đặc điểm nêu trên, có thể thấy rằng hệ thống sử dụng MOM có thiết kế hoàn toàn khác với hệ thống sử dụng RPC:

- MOM phù hợp với hệ thống được thiết kế có liên kết lỏng lẻo.
- RPC phù hợp với hệ thống cần liên lạc hai chiều.

3 Trung gian trung chuyển thông điệp - Message broker

Trung gian trung chuyển thông điệp là thành phần chính trong một hệ thống MOM, chịu trách nhiệm trung chuyển dữ liệu. Dù broker được coi là một thành phần trong bản thân MOM, nó là thành phần chính yếu nhất, và trong nhiều trường hợp cụm từ "message broker" được sử dụng tương đương với cụm từ MOM. Do vậy, ta có thể tạm bỏ qua producer và consumer, và phân tích broker.

Trước đây, các hệ thống broker thường chỉ được dùng trong các hệ thống của tổ chức lớn, do tiềm lực kinh tế và nhu cầu cho phép, với những sản phẩm của các công ty phần mềm lớn như EMS của TIBCO, WebSphere của IBM, webMethods của softwareAG [5]. Hiện nay, nhiều hệ thống vừa và nhỏ cũng có nhu cầu scale out, do đó đã có rất nhiều dự án MOM mã nguồn mở xuất hiện, tiêu biểu là RabbitMQ, Apache Kafka, ActiveMQ,...

Phần này tập trung vào phân tích một số khía cạnh về cách broker hoạt động.

3.1 Cơ chế quản lý thông điệp

Thông thường, các broker quản lý việc truyền thông điệp bằng cách chia ra các *hàng chờ* (queue) hay *chủ đề* (topic); hai từ này nhìn chung được dùng tương đương nhau. Khi một producer *xuất bản* gửi một thông điệp vào một hàng chờ, thông điệp đó sẽ được gửi đến các consumer đã *đăng ký* nhận thông điệp từ hàng chờ đó, chứ không phải là gửi đến mọi consumer trong toàn hệ thống. Cơ chế này được gọi là *xuất bản-đăng ký* (publish-subscribe, hay viết tắt là pub/sub).

Cơ chế pub/sub có thể coi là một bước trừu tượng hóa trên các cơ chế cũ như RPC. Với RPC, bên gửi cần biết chính xác điểm cuối, nhưng với MOM, bên gửi (producer) chỉ cần biết một hàng đợi, hàng đợi này có thể là đại diện cho (nhiều hơn) một chức năng nào đó.

Ví dụ, với hệ thống crawler, khi một người gửi thông tin một đường link vào producer, producer đó có thể phân tích để gửi vào hàng đợi chuyên xử lý trang VnExpress, hoặc đưa vào hàng đợi chuyên xử lý Zing,... Đăng ký vào các hàng đợi đó là các crawler tương ứng.

Chú ý rằng một số tài liệu còn nhắc đến một mô hình nhũ của MOM bên cạnh pub-sub là mô hình điểm-điểm (point-to-point). Điểm-điểm có thể được coi là một trường hợp đặc biệt của pub-sub, với chỉ một producer và một consumer. Khi đã nhắc đến mô hình điểm-điểm, các tài liệu này cũng phân biệt luôn hàng đợi và chủ đề: hàng đợi dành cho mô hình điểm-điểm, còn chủ đề là cho mô hình pub-sub.

3.2 Thời gian sống

Do MOM chỉ là một trung gian, dữ liệu trong đó cuối cùng sẽ được xử lý và lưu trữ bởi consumer, nên dữ liệu trong hàng chờ thường được xóa đi khi đã chuyển đến hết các consumer cần chuyển. Nếu chưa chuyển đến hết các consumer, dữ liệu vẫn sẽ được lưu trong MOM đợi truyền tải lại đến các consumer chưa nhận được.

3.3 Làm việc với nhiều consumer

Khi có nhiều consumer cùng đọc từ một hàng chờ, có hai cách xử lý chính:

3.3.1 Cân bằng tải

Trong chế độ cân bằng tải, mỗi thông điệp sẽ được xử lý bởi một consumer, do đó tốc độ xử lý thông điệp được tăng lên đáng kể do được xử lý song song.

3.3.2 Fan-out

Trong chế độ fan-out [6], thông điệp được gửi đến mọi consumer để xử lý. Tốc độ xử lý hàng chờ không tăng, tuy nhiên dữ liệu lại được xử lý theo nhiều cách khác nhau ở nhiều consumer khác nhau.

3.4 Lưu trữ và thông báo

Do nhu cầu truyền tải lại, MOM bắt buộc phải lưu các thông điệp. Về mặt nguyên tắc, một cơ sở dữ liệu là đủ để tạo ra một broker:

- Producer ghi thông điệp vào cơ sở dữ liệu.
- Consumer đọc thông điệp ra theo chu kì (polling), lấy dữ liệu từ sau lần đọc gần nhất.

Tuy nhiên, do yêu cầu ngày càng tăng về tốc độ, việc consumer chủ động đọc dữ liệu ra bắt đầu có nhiều overhead:

- Tăng tần suất đọc dữ liệu: giảm xác suất đọc được dữ liệu mới.
- Giảm tần suất đọc dữ liệu: tăng độ trễ do chậm phát hiện dữ liệu.

Do đó, cách tốt hơn là thông báo consumer khi có dữ liệu mới. Cơ sở dữ liệu có một tính năng phù hợp, đó là trigger, tuy nhiên tính năng này không phải là một thiết kế tốt, được tính toán từ đầu khi tạo ra tiêu chuẩn SQL, mà được thêm vào sau đó.

Lý do trên kết hợp với thời gian sống ngắn của dữ liệu (khác với cơ sở dữ liệu thường lưu dữ liệu hàng năm trời), và mẫu truy cập tuần tự (khác với mẫu truy cập ngẫu nhiên của cơ sở dữ liệu), nên để tối ưu hiệu năng, các broker có cách lưu trữ dữ liệu riêng [3], thay vì dùng cơ sở dữ liệu đa dụng có sẵn.

Mục 4 tiếp theo sẽ giới thiệu một số chi tiết về cách lưu trữ dữ liệu của Apache Kafka.

3.5 Tiêu chuẩn

Khác với cơ sở dữ liệu quan hệ và SQL, không có một tiêu chuẩn thống nhất trong toàn ngành về MOM. Tuy nhiên có hai tiêu chuẩn nổi bật hơn cả là Java Message Service (JMS) của Java và Advanced Message Queuing Protocol (AMQP) của OASIS/ISO.

3.5.1 Java Message Service - JMS

JMS là một bộ API trong Java EE cho phép người dùng gửi và nhận thông tin liên tiếp theo kiểu MOM. Trong JMS, broker được gọi là JMS Provider.

Do JMS chỉ đơn giản là một bộ API, cài đặt chi tiết của mọi thành phần, bao gồm cả giao thức để giao tiếp giữa producer-broker-consumer đều không được định nghĩa. Do đó, 2 hệ thống MOM tuân theo JMS chưa chắc đã kết nối được với nhau, dù có chung cách dùng.

3.5.2 Advanced Message Queuing Protocol - AMQP

AMQP là một giao thức tầng ứng dụng cho MOM dùng để liên lạc giữa producer-broker-consumer.

Do AMQP là một giao thức gửi dữ liệu ở dạng cơ bản nhất - byte, bất kì hai ứng dụng nào cài đặt nó đều có thể giao tiếp với nhau. Apache ActiveMQ là một MOM có sử dụng giao thức AMQP, và cùng lúc cài đặt bộ API JMS.

4 Apache Kafka

4.1 Giới thiệu

Kafka là một MOM mã nguồn mở viết bằng Java và Scala. Được phát triển bởi Jay Kreps tại LinkedIn vào năm 2011, dự án này đã được ủng hộ cho Apache Software Foundation và trở thành một trong những MOM phổ biến nhất hiện nay. Kafka được chú ý bởi khả năng ghi dữ liệu với tốc độ cao, độ trễ thấp và dễ dàng scale out, phù hợp với các ứng dụng cần thu thập dữ liệu thời gian thực [2].

4.2 Kiến trúc

4.2.1 Producer - Broker - Consumer

Trong Kafka, một thông điệp được gọi là một bản ghi (record). Mỗi bản ghi gồm một khóa, một giá trị, và một nhãn thời gian.

Về cơ bản, Kafka có kiến trúc giống như mọi MOM khác, với ba thành phần producer-broker-consumer. Tuy nhiên, phía consumer của Kafka có chút biến tấu. Kafka có consumer group, là một nhóm các consumer. Tương tác của broker với consumer được thực hiện như sau [2, 1]:

- Mỗi thông điệp được broker gửi đến mọi group đã đăng ký vào chủ đề tương ứng: fan-out.
- Trong mỗi group, mỗi thông điệp được gửi đến một consumer: load balancing.

Nhờ có group, Kafka đạt được lợi thế của cả cơ chế fan-out (nhiều loại group consumer) và cơ chế load balancing (nhiều consumer để tăng tốc xử lý).

4.2.2 Cluster Broker

Trong Kafka, broker không phải là một máy riêng lẻ mà gồm nhiều máy khác nhau, để phục vụ tính năng replication. Ngoài ra, Kafka còn dùng




Figure 3: Consumer group trong Kafka.

ZooKeeper để chứa cài đặt broker.
Toàn bộ các máy hợp lại thành một
cụm broker.

4.3 Phân mảnh và Nhân bản

4.3.1 Phân mảnh: cấu trúc log

Trong Kafka, một topic được *phân mảnh* thành các partition như sau:




Figure 4: Cấu trúc topic trong Kafka [2].

Các partition này có cấu trúc log. Từ "log" ở đây hiểu theo nghĩa "một bản ghi chỉ thêm vào đuôi", thể hiện cách dữ liệu được ghi. Các file log này chính là cấu trúc dữ liệu cốt lõi của Kafka, là một trong hai yếu tố giúp Kafka có tốc độ cao (sẽ nói ở phần sau).

Khi producer đưa một record vào topic, record đó sẽ được thêm vào đuôi một partition, và được gán một số gọi là offset. Trong mỗi partition, số này tăng dần theo các record được thêm vào, từ đó có thể thấy trong mỗi partition, các record được sắp xếp theo thứ tự offset từ thấp đến cao, như trong hình 4.

Do việc ghi tuần tự vào đuôi mỗi log, việc đọc cũng trở nên dễ dàng. Consumer chỉ cần nhớ offset gần nhất đã đọc, và đọc tuần tự tiếp từ đó, hoặc thậm chí có thể trở offset về sâu nữa để xử lý dữ liệu cũ nếu cần.

Có một số lý do mà Kafka chia topic ra thành các partition:

- Scale out: Nếu topic quá lớn, chỉ cần thêm máy broker và thêm partition.
- Tăng tốc xử lý: Một số trường hợp cần xử lý dữ liệu theo đúng trình tự thời gian, do đó chỉ được một consumer xử lý. Nếu không có partition, một consumer đó phải xử lý cả một topic. Vì có partition nên có thể dùng nhiều (nhưng vẫn không nhiều như load balancing) consumer, mỗi consumer xử lý một partition.
- Đánh đổi hợp lý giữa tốc độ và khả năng đảm bảo thứ tự: Với nhiều ứng dụng, thứ tự của nhận thông điệp giữa hai consumer rất quan trọng. Cách

truyền thống là đảm bảo chỉ một consumer xử lý toàn bộ topic. Tuy nhiên Kafka chia topic ra các partition, và giao mỗi partition cho một consumer, do đó Kafka có thể tăng tốc độ xử lý (dĩ nhiên hệ thống sử dụng cũng cần được thiết kế phù hợp).

4.3.2 Nhân bản: master-slave

Mỗi partition có thể được nhân bản ra và lưu ở nhiều máy broker. Với mỗi partition, có một máy broker được chọn làm master, và một số máy khác làm slave. Các thao tác trên dữ liệu đều được thực hiện ở master, và cập nhật được lan truyền sang các máy slave. Nếu master bị lỗi, ZooKeeper sẽ cử một slave lên làm master.

Có hai lí do mà Kafka cần nhân bản partition:

- Sao lưu
- Tăng tốc đọc: consumer có thể đọc từ nhiều máy broker (có từ Kafka 2.4)

4.4 Nhập/xuất hiệu năng cao

Có hai lí do chính cho tốc độ cao của Kafka, và đều liên quan đến IO:

4.4.1 Đọc ghi tuần tự

Thông thường, ổ cứng được coi là quá chậm, phần vì lí do công nghệ, phần vì người dùng có mẫu truy cập ngẫu nhiên. Theo bài test của Kafka, ổ cứng cơ truyền thống nếu chạy RAID và ghi tuần tự có thể có băng thông 600 MB/s, tuy nhiên cùng hệ thống ấy nếu ghi ngẫu nhiên thì chỉ được 1/6000 tốc độ ghi tuần tự.

Do sử dụng cấu trúc log, việc ghi chỉ gồm ghi tuần tự vào cuối file (append), việc đọc cũng tuần tự theo thứ tự offset, tốc độ đọc-ghi của Kafka rất nhanh. Kết hợp thêm ghi theo lô ở phía producer, prefetch của hệ điều hành, Kafka có thể có thông lượng rất cao mà không nhất thiết phải đầu tư vào SSD đắt tiền.

4.4.2 Zero copy

Thông thường, để gửi file qua socket, hệ điều hành cần làm những việc sau:

- Đọc từ đĩa vào *kernel* pagecache
- Đọc từ *kernel* pagecache vào *user-space* buffer
- Đọc từ *user-space* buffer vào *kernel* socket buffer
- Đọc từ *kernel* socket buffer vào buffer card mạng

Với 4 lần copy và 2 lệnh hệ thống, cách này rất mất thời gian. Tuy nhiên, các hệ điều hành có cơ chế zero copy để copy trực tiếp vào buffer card mạng.

4.5 Producer và Consumer

4.5.1 Producer

Producer có thể chọn partition để ghi, và có thể gửi lệnh ghi theo lô để giảm overhead.

4.5.2 Consumer

Giống với đa số các MOM khác, consumer lấy dữ liệu từ broker chứ không phải broker "đẩy" dữ liệu xuống consumer.

4.6 Ứng dụng

Ứng dụng quan trọng nhất của Kafka chính là làm một hệ thống MOM. Trong vai trò này, Kafka đã được sử dụng thành công trong các hệ thống lớn, yêu cầu tốc độ thời gian thực. Cụ thể hơn, có hai ca sử dụng phổ biến:

- Event sourcing: Là một mô hình thiết kế. Trong mô hình này, các thay đổi trạng thái của dữ liệu được ghi lại và được gửi đến các hệ thống khác thông qua MOM. Với chuỗi các thay đổi này, bên nhận có thể "replay" và đạt được trạng thái dữ liệu của bên gửi.
- Analytic pipeline:

Ngoài ra, với hệ thống lưu trữ được phân mảnh và nhân bản, Kafka có thể đóng vai trò làm một hệ thống lưu trữ.

Điểm khác biệt của Kafka và một số hệ thống đối thủ như ActiveMQ là mức độ hỗ trợ cho xử lý dữ liệu dạng luồng (stream data). Dữ liệu dạng luồng coi dữ liệu là một luồng đến và đi liên tục. Đây là quan điểm khác với quan điểm khác với ý tưởng của xử lý dữ liệu theo lô (batch data), do để tạo được "lô" thì dữ liệu phải có một cách phân nhóm hữu ích (ví dụ, nhóm dữ liệu theo năm). Với dữ liệu dạng luồng, người ta chấp nhận rằng dữ liệu không thể được "gom" lại như thế (hoặc chỉ "gom" một số điểm dữ liệu gần nhau). Từ đó, hệ thống dữ liệu luồng có thể đạt được tốc độ xử lý gần với thời gian thực.

Các hệ thống MOM mới đều hỗ trợ phần nào các thao tác aggregator và join trong xử lý dữ liệu dạng luồng, tuy nhiên với các bài toán phức tạp hơn thì vẫn cần những hệ thống xử lý luồng ở ngoài như Storm, Spark,... Hiện tại chỉ Kafka mới có hệ thống xử lý luồng riêng là Kafka Stream.

Tuy nhiên, các hệ thống MOM cổ điển hơn như ActiveMQ hay RabbitMQ, và các hệ thống không broker (cho đến đây, các MOM được bàn đến đều có broker) như ZeroMQ vẫn có chỗ đứng riêng. Một số nhược điểm của Kafka có thể kể đến là quá cồng kềnh với một hệ thống nhỏ, đồng thời không hỗ trợ những thao tác phức tạp trên dữ liệu như giao dịch (do đã đánh đổi cách lưu trữ dữ liệu phức tạp với hiệu năng cao).

5 Demo Kafka

5.1 Bài toán: Crawler

Cho đường link một bài báo trên VnExpress hoặc Zing. Crawl dữ liệu (tiêu đề, thân bài,...) bài báo đó và các bài báo liên quan về.

5.2 Lời giải

Có một producer để nhận link bài báo từ người dùng, 2 consumer ứng với hai trang báo để crawl dữ liệu. Có hai topic tương ứng với hai báo.

Khi producer nhận được link bài báo, nó kiểm tra xem bài báo là của báo nào, rồi gửi vào topic tương ứng, đến consumer và crawler tương ứng. Dữ liệu crawl được sẽ lưu lại ở dạng JSON và lưu ở thư mục gọi producer.

Chú ý do Kafka tối ưu cho việc trao đổi thông tin một chiều/bất đồng bộ, việc dựng thêm một topic để trả về tận tay producer là khiến cường, code demo không dùng cách này.

References

- [1] *Apache Kafka Implementation*. URL: <https://web.archive.org/web/20200421054509/https://kafka.apache.org/documentation/> (visited on 04/21/2020).
- [2] *Apache Kafka Introduction*. URL: <https://web.archive.org/web/20200413031434/https://kafka.apache.org/intro> (visited on 04/13/2020).
- [3] Don Carney et al. “Monitoring Streams: A New Class of Data Management Applications”. In: *Proceedings of the 28th International Conference on Very Large Data Bases*. VLDB '02. Hong Kong, China: VLDB Endowment, 2002, pp. 215–226.
- [4] Edward Curry. “Message-Oriented Middleware”. In: July 2005, pp. 1–28. ISBN: 978-0-470-86206-3. DOI: 10.1002/0470862084.ch1.
- [5] Martin Kleppmann. *Designing Data-Intensive Applications*. Beijing: O'Reilly, 2017. ISBN: 978-1-4493-7332-0. URL: <https://www.safaribooksonline.com/library/view/designing-data-intensive-applications/9781491903063/>.
- [6] Bartosz Konieczny. *Big Data patterns implemented - fan-out ingress in Apache Spark Structured Streaming*. May 2019. URL: <https://www.waitingforcode.com/data-engineering-patterns/big-data-patterns-implemented-fan-out-ingress-apache-spark-structured-streaming/read> (visited on 04/17/2020).
- [7] Debu Panda et al. *EJB 3 in Action*. USA: Manning Publications Co., 2014. Chap. 4. ISBN: 1935182994.
- [8] Abraham Silberschatz, Peter B. Galvin, and Greg Gagne. *Operating System Concepts*. 9th. Wiley Publishing, 2012. ISBN: 1118063333.

- [9] Kai Waehner. *Apache Kafka vs. Enterprise Service Bus (ESB) – Friends, Enemies or Frenemies?* July 2018. URL: <https://web.archive.org/web/20181225021136/https://www.confluent.io/blog/apache-kafka-vs-enterprise-service-bus-esb-friends-enemies-or-frenemies/> (visited on 04/17/2020).